

Flops:

Посчитаем количество операций для нашей сети (S, B)

1-ый слой: $7 \cdot 7 \cdot 3 \cdot 2$ - для одного положения ядра свёртки
Поскольку количество перемещений свёртки: $(\frac{S}{2})^2$
Таких свёрток: 32

$$\Rightarrow \text{1-ый слой: } 7 \cdot 7 \cdot 3 \cdot 2 \cdot \frac{S^2}{4} \cdot 32$$

$$\text{2-ой слой: } 5 \cdot 5 \cdot 32 \cdot 64 \cdot 2 \cdot \left(\frac{S}{4}\right)^2$$

$$\text{3-ий слой: } 3 \cdot 3 \cdot 64 \cdot 128 \cdot \left(\frac{S}{4}\right)^2 \cdot 2$$

$$\text{4-ый слой: } 128 \cdot 256 \cdot \left(\frac{S}{8}\right)^2 \cdot 2$$

$$\text{5-ый слой: } 3 \cdot 3 \cdot 256 \cdot 256 \cdot \left(\frac{S}{8}\right)^2 \cdot \frac{1}{4} \cdot 2$$

$$\text{6-ой слой: } 256 \cdot 512 \cdot \left(\frac{S}{16}\right)^2 \cdot 2$$

$$\text{7-ой слой: } 512 \cdot \left(\frac{S}{16}\right)^2$$

$$\text{8-ой слой: } 512 \cdot 256 \cdot 2 + 256 \cdot 100 \cdot 2$$

Просуммировав операции по каждому слою и умножив на B мы получим:

$$\text{Flops}(B, S) = B(17714S^2 + 313344)$$

Теперь посчитаем нагрузку по памяти методу (B, S):

Операции ReLU (inplace = True) не дают нагрузку на память
свёртка 1: $7 \cdot 7 \cdot 3$ - одна свёртка, таких 32 $\Rightarrow 7 \cdot 7 \cdot 3 \cdot 32$

$$\text{свёртка 2: } 5 \cdot 5 \cdot 32 \cdot 64$$

$$\text{свёртка 3: } 3 \cdot 3 \cdot 64 \cdot 128$$

$$\text{свёртка 4: } 1 \cdot 1 \cdot 128 \cdot 256$$

$$\text{свёртка 5: } 3 \cdot 3 \cdot 256 \cdot 256$$

$$\text{свёртка 6: } 1 \cdot 1 \cdot 256 \cdot 512$$

$$\text{полносвязный слой 1: } (512 + 1) \cdot 256$$

$\uparrow$
bias

$$\text{полносвязный слой 2: } (256 + 1) \cdot 100$$

Просуммировав получаем количество параметров CNN+FC

Умножим на 4 байта и получим потребляемую память параметрами

Посчитаем нагрузку на память для промежуточных результатов

после операций свёртки, maxPool, adaptive AvgPool для тензора изображения

Входное изображение: $3 \cdot S^2$

После 1 свёртки: $8S^2$

После maxPool: $32 \cdot \left(\frac{S}{4}\right)^2 = 2S^2$

← 1-ый блок

Суммарно: $13S^2$ потребление

После второй свёртки:

$$2S^2 + 3S^2 + 4S^2 = 9S^2$$

После третьей свёртки:

$$3S^2 + 4S^2 + 2S^2 = 9S^2$$

После четвёртой свёртки:

$$3S^2 + 4S^2 + S^2 = 8S^2$$

После пятой свёртки:

$$3S^2 + S^2 + 2S^2 = 6S^2$$

В результате берём $13S^2$ поскольку это типовой размер тензора

Умножаем результат на размер бита В и на 4 байта и получаем:

$$4161296 + 52BS^2 \text{ байт}$$

На практике оказалось что есть буфер cuBLAS размером в 2^{25} байт

$$4161296 + 2^{25} + 52BS^2 \text{ байт} \approx 32 \text{ мбайт} + 52BS^2 \text{ байт}$$

Также есть индекс MaxPool: int64 размером $16BS^2$

$$4161296 + 2^{25} + 68BS^2 \text{ байт}$$

latency:

Мик по памяти уже посчитан и равен 4. ($1040324 + 13BS^2$)

Посчитаем у каждого оператора чтение входа и запись выхода в свёрток: $(3+8) + (2+4) + (4+2) + (2+4) + (4+1) + (1+2) = 37$

6 ReLU: $2 \cdot (8+4+2+4+1+2) = 42$

MaxPool: $8+2 = 10$

Чтение входа GlobalAvgPool: 2

По итогу получаем: 91

Оставшиеся небольшие тензоры дают:

$$2148B = (512 + (512 + 256) + (256 + 256) + (256 + 100))B$$

По итогу получаем

$$D(S, B) = 4(91BS^2 + 2148B + 1040324) \text{ байт}$$

Каждый оператор запускает одно ядро со средней накладной задержкой τ , вычисления и передача данных частично перекрываются, поэтому время полезной работы оценивается из более медленной из 2х ветвей.

$$T(S, B, \theta) = 17\tau + \max\left(\frac{B(17714S^2 + 313344)}{P}, \frac{4(91BS^2 + 2148B + 1040324)}{W}\right)$$

где τ - секунды на запуск, P - FLOPS/c, W - байты/c

17 - это 6 свёрток + 7 ReLU + MaxPool + GlobalAvgPool + 2 Linear.

По результатам подбора параметров для $T(S, B, \theta)$ получилось

$$\tau = 15,56 \text{ мкс/запуск}, P = 6,28 \text{ TFLOPS/c}, W = 140,9 \text{ TB/c}$$

энергию:

Предполагается, что ГРИ тратит энергию на протяжении всего времени с эффективной базовой мощностью P_0 . Дополнительные затраты приближают линейными функциями тепла вычислений и объёма обращений к памяти. Коэффициенты P_0 , E_F , E_D подбирают по измеренной энергии, а время T берут из модели задержки. Во времени вычисления и передача данных могут перекрываться, поэтому там стоит $\max$, их энергетические затраты складываются.

$$E(S, B, \theta) = P_0 T(S, B, \theta) + E_F \frac{F(S, B)}{10^9} + E_D \frac{D(S, B)}{10^9}$$

$$P_0 = 51,26 \text{ Вт}, E_F = 0,02116 \text{ Дж/GFLOP}, E_D = 0 \text{ Дж/ГБ}$$

Итог:

Измерены 132 пары (S, B) , 63 использованы для калибровки, 69 только для проверки. На этих 69 парах относительная ошибка составила 13,2% для памяти, 16,9 % для времени 8,9 % для энергии